

USTC 概率论与数理统计笔记速查版

基于《概率论与数理统计（繆百齐 张伟平）》及《概率论与数理统计（陈希孺）》
2024年于合肥,Ferry
2026年于合肥,Ferry,Grok,Gemini and GPT

- USTC 概率论与数理统计笔记速查版
 - 随机变量及其分布
 - 离散型
 - 连续型
 - 随机变量函数的分布
 - 多维随机变量及其分布
 - 多维随机变量的联合分布
 - 边缘分布与条件分布
 - 随机变量的独立性
 - 数字特征 协方差与相关系数
 - 随机变量函数的分布
 - 随机变量的数字特征和极限定理
 - 数学期望与中位数
 - 方差与矩
 - 熵
 - 大数定理与中心极限定理
 - 随机变量序列的收敛性
 - 大数定理
 - 中心极限定理
 - 统计学基本概念
 - 基本概念
 - 三大分布
 - 参数点估计
 - 基本概念
 - 矩估计法
 - 最大似然估计 MLE
 - 优良性准则
 - 点估计量的大样本理论
 - 区间估计
 - 基本概念
 - 枢轴变量法
 - 大样本方法
 - 自助法置信区间
 - 置信限
 - 假设检验
 - 基本概念
 - 正态总体参数检验
 - 比例p的检验
 - 似然比检验 LRT
 - p值
 - 非参数假设检验
 - 拟合优度检验
 - 威尔克森秩和检验 Wilcoxon Rank-Sum Test
 - 符号检验 Sign Test
 - 其他非参数检验
 - 相关分析与回归分析
 - 相关分析 Correlation Analysis
 - 回归分析 Regression Analysis
 - 多元回归中的自变量选择与模型诊断
 - 附录

随机变量及其分布

离散型

1. 概率质量函数: $P(X = x_k) = p_k, k = 1, 2, 3, \dots, n, \dots$
 p_k 即为概率质量函数
2. 0-1分布:也称为伯努利分布、两点分布,即取值只有0和1,是特殊的二项分布
 - 期望: p
 - 方差: $p(1 - p)$
3. 离散均匀分布: $P(X = x_k) = \frac{1}{n}, k = 1, 2, 3, \dots, n, \dots$,即等概率
 - 期望
 - 方差
4. 二项分布: 表示n次实验中成功的次数,设为k,其中每次实验成功概率为p且独立: $P(X = x_k) = C_n^k p^k (1 - p)^{n-k}, k = 1, 2, 3, \dots, n$,记为 $X \sim B(n, p)$
 - 期望: np
 - 方差: $np(1 - p)$
5. 负二项分布: X_r 表示第r次实验成功发生时的试验次数k,其中每次实验成功概率为p且独立: $P(X = x_k) = C_{n-1}^{k-1} p^r (1 - p)^{k-r}, k = 1, 2, 3, \dots$,记为 $X \sim NB(r, p)$
 - 期望: $\frac{r}{p}$
 - 方差: $\frac{r(1-p)}{p^2}$
6. 几何分布: 几何分布即负二项分布中r=1的特殊情形,即第一次实验成功时进行的实验次数: $P(X = x_k) = p(1 - p)^{k-1}, k = 1, 2, 3, \dots$,记为 $X \sim Ge(p)$
几何分布的无记忆性: $P(X > m + n | mid X > m) = P(X > n)$,即在前m次实验都失败的条件下,实验m+n次成功的概率与从0开始实验n次概率相同,就仿佛它忘了前m次实验,即无记忆性
 - 期望: $\frac{1}{p}$
 - 方差: $\frac{1-p}{p^2}$
7. 泊松分布
 - 泊松分布: $P(X = k) = e^{-\lambda} \frac{\lambda^k}{k!}$,这表示在**给定的时间或空间D**中,事件的发生次数为k的概率,其中 λ 是在**该时间或空间中事件的平均发生次数**。在二项分布的p很小时,且 $\lambda = np$ 为一个定值时,可以将泊松分布作为二项分布的近似,但此时的 λ 是在二项分布整个时间或空间中发生次数的平均值 (本来二项分布的期望就是 np)。
 - 期望: λ
 - 方差: λ
 - 泊松逼近定理: 即二项分布中 $X_n \sim B(n, p), \lim_{p \rightarrow 0} np \rightarrow \lambda > 0, \lim_{n \rightarrow \infty} P(X_n = k) = e^{-\lambda} \frac{\lambda^k}{k!}, k = 0, 1, 2, \dots$

连续型

1. 分布函数: X 为随机变量, x 为任一实数, $F(x) = P(X < x)$ 为随机变量 X 的 (累积) 分布函数 (cumulative distribution function, cdf)。
2. 概率密度函数: 设 X 的分布函数为 $F(X)$,若存在 $f(x) > 0$,使得 $F(x) = \int_{-\infty}^x f(t)dt$,且 X 为连续型随机变量, $f(x)$ 称为分布函数的概率密度函数 (pdf)。
3. 均匀分布: 随机变量 X 在有限区间 $a < X < b$ 内取值,且概率密度函数为 $f(x) = \frac{1}{b-a} I_{(a,b)}(x)$,即在 a, b 区间上每一点的取值是等概率的 (uniform distribution) ,记为 $X \sim U(a, b)$ 。
 - 期望: $\frac{a+b}{2}$
 - 方差: $\frac{(b-a)^2}{12}$
4. 指数分布: 概率密度函数: $f(x) = \lambda e^{-\lambda x} I_{(0,\infty)}(x)$,称 X 服从参数为 λ 的指数分布 (exponential distribution) ,记为 $X \sim Exp(\lambda)$ 。
指数分布也有无记忆性: $P(X > s + t | X > t) = P(X > s)$ 。
参数的含义: 若将 x 看作为时间,整体视作一批元件的寿命分布,则参数 λ 可视为单位时间内元件的失效率 (死亡率,发生故障的频率)。由于元件按这个比率不断失效,所以不断减少,斜率绝对值也越来越小。
 - 期望: $\frac{1}{\lambda}$ (平均寿命)
 - 方差: $\frac{1}{\lambda^2}$

5. 威布尔分布：上述指数分布只是考虑了一个平均死亡率,且它是一个定值;但在现实生活中是有老化现象的,即老化越严重,死亡率越高。
若取失效率为 λx^m , $\lambda > 0, m > 0, \alpha = m + 1$,则分布的密度函数为 $f(x) = \lambda \alpha x^{\alpha-1} e^{-\lambda x^\alpha}$

- 期望： $\frac{\alpha}{\lambda^\alpha} \Gamma(1 + \frac{1}{\alpha})$
- 方差： $(\frac{\alpha}{\lambda^\alpha})^2 [\Gamma(1 + \frac{2}{\alpha}) - (\Gamma(1 + \frac{1}{\alpha}))^2]$

6. 正态分布： $f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$, $x \in \mathbb{R}$,其中 μ, σ 为参数,记为 $X \sim N(\mu, \sigma^2)$;当 $\mu = 0, \sigma = 1$ 时称为标准化变换,密度函数记为 $\phi(x)$,其分布函数为标准正态分布函数,记为 $\Phi(x)$ 。

- 期望： μ
- 方差： σ^2

随机变量函数的分布

1. 离散型随机变量函数的分布
设 $Y = g(X)$,则 Y 的概率质量函数为

$$P(Y = y) = \sum_{g(x)=y} p_X(x)$$

(对所有使 $g(x) = y$ 的 x 求和)。

2. 连续型随机变量函数的分布

- 分布函数： $F_Y(y) = P(Y \leq y) = P(g(X) \leq y) = \int_{g(x) \leq y} f_X(x) dx$
- 密度函数变换公式 ($g(x)$ 严格单调且反函数可导)：
若 g 严格递增,则

$$f_Y(y) = f_X(g^{-1}(y)) \cdot \left| \frac{d}{dy} g^{-1}(y) \right|$$

- 若 g 严格递减,则符号取绝对值。
- 常用情形： $Y = X^2, Y = \ln X, Y = aX + b$ (线性变换) 等可直接套用。

多维随机变量及其分布

多维随机变量的联合分布

1. 联合分布函数： $F(x_1, x_2, \dots, x_k) = P(X_1 \leq x_1, X_2 \leq x_2, \dots, X_k \leq x_k)$
- 性质：单调不减性;右连续性; $F(\infty, \dots, \infty) = 1; F(-\infty, \dots) = 0$ 。
2. 离散型（联合概率质量函数）：
- 满足 $\sum_i \sum_j \dots p(x_i, x_j, \dots) = 1$ 。
 - 典型分布：多项分布 (Multinomial Distribution)： n 次独立重复试验,每次有 k 种可能结果 (概率分别为 $p_1, \dots, p_k$)。

$$P(X_1 = n_1, \dots, X_k = n_k) = \frac{n!}{n_1! n_2! \dots n_k!} p_1^{n_1} p_2^{n_2} \dots p_k^{n_k}$$

- 其中 $\sum n_i = n, \sum p_i = 1$ 。
3. 连续型（联合概率密度函数）：
- $F(x_1, \dots, x_k) = \int_{-\infty}^{x_1} \dots \int_{-\infty}^{x_k} f(t_1, \dots, t_k) dt_1 \dots dt_k$ 。
 - 典型分布：二元正态分布 $N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ ：

$$f(x, y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp \left[-\frac{1}{2(1-\rho^2)} \left(\frac{(x-\mu_1)^2}{\sigma_1^2} - \frac{2\rho(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} + \frac{(y-\mu_2)^2}{\sigma_2^2} \right) \right]$$

- ρ 为相关系数。

边缘分布与条件分布

1. 边缘分布 (Marginal Distribution)：
- 核心逻辑：“固定关心的,积掉/求和掉不关心的”。
 - 离散型： $P_X(x_i) = \sum_j p(x_i, y_j)$ 。

- 连续型: $f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy$ 。

2. 条件分布 (Conditional Distribution):

- 在已知某变量取值的条件下,另一变量的概率表现。
- 连续型: $f_{X|Y}(x|y) = \frac{f(x, y)}{f_Y(y)}$ (要求 $f_Y(y) > 0$)。
- 正态分布结论: 若 (X, Y) 服从二元正态分布,则其条件分布 $f_{X|Y}$ 仍为一元正态分布。

随机变量的独立性

1. 定义: $F(x_1, \dots, x_k) = F_1(x_1)F_2(x_2) \dots F_k(x_k)$ 对一切实数成立。
 - 密度函数形式: $f(x, y) = f_X(x)f_Y(y)$ 。
2. 性质:
 - 若 X, Y 独立,则 $g(X)$ 与 $h(Y)$ 也相互独立。
 - 期望性质: $E[XY] = E[X]E[Y]$ 。
 - 方差性质: $Var(X \pm Y) = Var(X) + Var(Y)$ 。

数字特征 协方差与相关系数

1. 协方差 (Covariance): 衡量两个变量协同变化的程度。

$$Cov(X, Y) = E[(X - E[X])(Y - E[Y])] = E[XY] - E[X]E[Y]$$

2. 相关系数 (Correlation Coefficient): 消除量纲影响的协方差。

$$\rho_{XY} = \frac{Cov(X, Y)}{\sqrt{Var(X)Var(Y)}}, \quad |\rho_{XY}| \leq 1$$

- $|\rho| = 1 \Leftrightarrow X, Y$ 线性相关; $\rho = 0$ 称 X, Y 不相关。
- 注意: 独立一定不相关,但不相关不一定独立 (正态分布下二者等价)。

3. 协方差矩阵: 对于 n 维随机变量 $\mathbf{X} = (X_1, \dots, X_n)^T$,其矩阵第 (i, j) 个元素为 $Cov(X_i, X_j)$ 。

随机变量函数的分布

1. 和的分布 (卷积公式):

设 $Z = X + Y$,若 X, Y 独立且连续:

$$f_Z(z) = \int_{-\infty}^{\infty} f_X(x)f_Y(z - x) dx$$

2. 商的分布:

设 $Z = X/Y, f_Z(z) = \int_{-\infty}^{\infty} |y|f(zy, y) dy$ 。

3. 极值分布 (Order Statistics):

设 $X_1, \dots, X_n$ 独立同分布 (i.i.d.) ,其分布函数为 $F(x)$:

- 最大值 $M = \max(X_1, \dots, X_n)$:

$$F_M(z) = P(X_1 \leq z, \dots, X_n \leq z) = [F(z)]^n$$

- 最小值 $L = \min(X_1, \dots, X_n)$:

$$F_L(z) = 1 - P(X_1 > z, \dots, X_n > z) = 1 - [1 - F(z)]^n$$

4. 常用结论补充:

- χ^2 分布: n 个独立标准正态随机变量的平方和: $\sum X_i^2 \sim \chi^2(n)$ 。
- Gamma 分布的加法性: $X \sim \Gamma(\alpha_1, \beta), Y \sim \Gamma(\alpha_2, \beta)$ 且独立 $\Rightarrow X + Y \sim \Gamma(\alpha_1 + \alpha_2, \beta)$ 。

随机变量的数字特征和极限定理

数学期望与中位数

数学期望的性质:

- 线性可加: 现有若干随机变量,不要求其之间互相独立,则有: $E(X_1 + X_2 + \dots + X_n) = \sum_{i=1}^n E(X_i)$ 。
- 独立可乘: 若随机变量 X, Y 相互独立,则有 $E(XY) = E(X)E(Y)$

方差与矩

方差

方差反映了一组数据的波动大小。表达式为 $Var(X) = E[(X - \overline{X})^2] = E[(X)^2] - E^2(\overline{X})$ 。

性质：

- $Var(cX) = c^2Var(X)$
- $Var(\sum_{i=1}^2 c_i X_i) = \sum_{i=1}^2 c_i^2 Var(X_i)$; (互相独立) 那么有: $Var(\overline{X}) = \frac{\sigma^2}{n}$

马尔可夫不等式: $Y \geq 0, \forall \epsilon > 0, P(Y \geq \epsilon) \leq \frac{E(Y)}{\epsilon}$;

设 $Y = (X - \overline{X})^2, \epsilon \rightarrow \epsilon^2$,有切比雪夫不等式: $P(|X - \overline{X}| \geq \epsilon) \leq \frac{Var(X)}{\epsilon^2}$ 。

矩与矩母函数

矩母函数: $M_X(s) = E[e^{sX}] = E[\sum_{k=0}^{\infty} \frac{X^k s^k}{k!}] = \sum_{k=0}^{\infty} E[X^k] \frac{s^k}{k!}$,其中 $\exists a, s \in [-a, a]$,即称其为矩母函数。矩母函数是为了得到各阶原点矩。

性质: 若存在正常数c,使得 X, Y 的矩母函数对所有 $s \in [-c, c]$ 都相等,则他们分布相同。

协方差与相关系数

一般的, $Var(X + Y) = Var(X) + Var(Y) + 2cov(X, Y)$;

协方差反映变量之间相关性。 $Cov(X, Y) = E[(X - \overline{X})(Y - \overline{Y})] = E(XY) - E(X)E(Y)$;

性质:

- $[Cov(X, Y)]^2 \leq Var(X)Var(Y)$,等号成立时当且仅当 X, Y 有严格线性关系;
 - $Cov(aX + bY, cX + dY) = acVar(X) + (ad + bc)Cov(X, Y) + bdVar(Y)$
- 相关系数: $\rho_{X,Y} = \frac{Cov(X,Y)}{\sqrt{Var(X)Var(Y)}} \leq 1$ 。由上可知,其成严格线性关系时等号成立,相关系数也是反应这个特性,即相关性强不强。

熵

熵体现的是变量的不确定性,熵越大不确定性就越大。

- 离散型: $H(X) = -\sum_{k=1}^{\infty} p_k \log_2(p_k)$
- 连续型: $H(X) = -\int_{-\infty}^{\infty} f_X(x) \ln f_X(x) dx$

可以看出,熵与变量具体取值无关,只与其概率分布有关。给定期望和方差,熵最大的是正态分布,具体证明暂略。

大数定理与中心极限定理

随机变量序列的收敛性

在讨论大数定理前,需明确依概率收敛的概念:

设 $X_1, X_2, \dots, X_n$ 为随机变量序列,若对于任意 $\epsilon > 0$,有:

$$\lim_{n \rightarrow \infty} P(|X_n - X| \geq \epsilon) = 0$$

则称序列 $\{X_n\}$ 依概率收敛于 X ,记为 $X_n \xrightarrow{P} X$ 。

大数定理

大数定理描述的是: 当试验次数足够多时,样本均值会稳定在期望值附近。

物理含义: 均值的算术平均具有“稳定性”,这是频率估计概率的理论基石。

1. 切比雪夫大数定理

- 条件:** X_i 相互独立,期望 $E(X_i)$ 和方差 $Var(X_i)$ 均存在,且方差有共同的上界 (即 $Var(X_i) \leq C$)。
- 结论:** $\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P} \frac{1}{n} \sum_{i=1}^n E(X_i)$ 。
- 意义:** 均值的波动随 n 增大而消失。

2. 伯努利大数定理

- 条件:** S_n 为 n 重伯努利试验中事件 A 发生的次数, p 为 A 发生的概率。
- 结论:** $\frac{S_n}{n} \xrightarrow{P} p$ 。

- 意义：当 n 很大时,频率依概率收敛于**概率**。

3. 辛钦大数定理

- 条件: X_i 独立同分布 (i.i.d.),期望 $E(X_i) = \mu$ 存在。
- 结论: $\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P} \mu$ 。
- 意义: 相比切比雪夫定理,它放宽了对方差的要求,但加强了“同分布”的条件。

中心极限定理

中心极限定理描述的是：大量独立随机变量的和,其分布趋向于**正态分布**。

物理含义：无论原始分布是什么形状（均匀、指数、甚至离散分布），只要加总的数量足够多,最终都会呈现出“钟形曲线”。

1. 林德伯格-列维定理

- 条件: X_i 独立同分布, $E(X_i) = \mu, Var(X_i) = \sigma^2 > 0$ 。
- 结论: 当 $n \rightarrow \infty$ 时,随机变量 $Z_n = \frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n}\sigma}$ 的分布函数收敛于标准正态分布 $\Phi(x)$ 。
- 应用: $\sum X_i \approx N(n\mu, n\sigma^2)$ 或 $\bar{X} \approx N(\mu, \frac{\sigma^2}{n})$ 。

2. 棣莫弗-拉普拉斯定理

- 条件: $X_n \sim B(n, p)$ (二项分布)。
- 结论: 当 n 很大时, X_n 近似服从正态分布 $N(np, np(1-p))$ 。

$$\frac{X_n - np}{\sqrt{np(1-p)}} \xrightarrow{d} N(0, 1)$$

- 意义: 它是林德伯格-列维定理在二项分布下的特殊情况,也是工程中常用的近似手段。

统计学基本概念

基本概念

- 总体 (population)：研究对象的全体。
- 样本 (sample)：从总体中随机抽取的部分观测值 $X_1, \dots, X_n$ (简单随机样本要求独立同分布)。
- 统计量 (statistic)：样本的函数 $T = T(X_1, \dots, X_n)$,不含未知参数。
- 参数 (parameter)：描述总体分布的未知常数 θ 。
- 抽样分布 (sampling distribution)：统计量 T 的概率分布 (用于推断)。
- 充分统计量：包含样本关于参数 θ 全部信息的统计量 (因子分解定理)。

三大分布

卡方分布

- 数学期望: n ;
- 方差: $2n$;
- 性质: 若 $X \sim \chi_m^2, Y \sim \chi_n^2, X, Y$ 独立,则 $Z = X + Y \sim \chi_{m+n}^2$ (这是非常显然的) ;

t分布

- 数学期望: 0,当 $n \geq 2$ 由对称性可得出;
- 方差: $\frac{n}{n-2}$,当 $n \geq 3$;
- 性质:
 - $n = 1$ 时, t_1 分布即为柯西分布,此时概率密度函数为 $f_1(t) = \frac{1}{\pi(1+t^2)}$; (注: 柯西分布期望不存在!)
 - $n \rightarrow \infty$ 时, t_n 分布的概率密度函数趋近于标准正态分布概率密度函数,即 $\lim_{n \rightarrow \infty} f_n(t) = \phi(t)$;

F分布

- 性质:
 - 若 $Z \sim F_{m,n}$, 则 $1/Z \sim F_{n,m}$, 由F分布的结构可以看出来;
 - 若 $T \sim t_n^2$, 则 $T^2 \sim F_{1,n}$, 同样直观上可以看出来;
 - $F_{m,n}(1-\alpha) = 1/F_{n,m}(\alpha)$, 比较实用的一个;

参数点估计

基本概念

利用样本 X 统计量估计参数 θ , 得到 $\hat{\theta}(X)$, 一般应用于在只有数据分布没有该参数准确信息下作为该参数的近似代替

矩估计法

PS:矩估计在二阶及以上需要修正

- j阶中心距： $\alpha_j = E(X^j)$
- j阶原点矩： $\mu_j = E[(X - \overline{X})^j]$

利用矩表达式的结构,可以求出一些参数的估计值。

易得 常见参数 $E(X)$ 与 σ^2 分别为(全部样本的)一阶原点矩与二阶中心矩。

最大似然估计 MLE

即给定的数据 X ,待估计参数 θ ,使给定数据出现概率最大的 θ 即为估计值 $\hat{\theta}$ 。

- 似然函数：样本 $X = (X_1, X_2, ..., X_n)$ 的联合概率密度函数或联合概率质量函数 $f(x; \theta) = f(x; \theta_1, \theta_2, ... \theta_n)$ 。

$\theta = (\theta_1, \theta_2, ... \theta_n) \in \Theta$, x 为样本 X 的一个样本值。通常固定 x ,将 $f(x; \theta)$ 看作 θ 的函数,即似然函数 (likelihood function), 记为 $L(\theta; x)$ 或 $L(\theta)$ 。

即求使 $L(\theta; x)$ 最大的 θ

为与矩估计区分,矩估计一般记为 $\hat{\theta}_m$,最大似然估计记为 $\hat{\theta}_L$ 。

为求极值,一般使 $l = \ln L$,用 l 对各个待估计参数求偏导,为的是省去连乘所导致的计算繁琐问题。

- 某些情况 l 偏导不存在,这时要回到本源定义,即求解目的是求出使 L 最大的 θ ,在此条件下通过一些技巧与方法求出 $\hat{\theta}_L$
- 求偏导后不易求解,如柯西分布
- 极值可能取在区间端点处,需进行比较

PS:

- 最大似然估计可能不唯一
- 某些情况分布的矩估计不存在,比如柯西分布
- 矩估计法在总体分布情况（比如或是正态分布,或是二项分布等等）未知情况下,根据样本值进行估计;而极大似然估计需要整体分布情况,需要知道是什么分布,比如其概率密度函数或概率质量函数,不然无法通过求导或其他方法求出极值

优良性准则

假设某个参数有多种估计结果,那也就是看其中哪些估计效果更好,包括**无偏性**和**均方误差**等。

- 点估计无偏性：估计的准确性
 - 偏差与无偏性：设 $\hat{g}(X)$ 是 $g(\theta)$ 的一个估计量,称 $E_{\theta}(\hat{g}(X)) - g(\theta)$ 为估计量 $\hat{g}(X)$ 的偏差。若对任意可能的 $\theta \in \Theta$ 都有偏差为0,则 $\hat{g}$ 是 $g(\theta)$ 的一个无偏估计量。
PS：对于求期望的解释：取了多组 X 数据,对每组 X 求出来的 $\hat{g}(X)$ 做平均。
 - 渐近无偏估计： $\hat{\theta}(X)$ 是 θ 的一个点估计,如果 $\lim_{n \rightarrow \infty} E(\hat{\theta}(X)) = \theta, \forall \theta \in \Theta$,则称 $\hat{\theta}(X)$ 是 θ 的一个渐近无偏估计。
- 无偏估计的方差：估计的波动大小
 - 均方误差（误差平方的平均）： $MSE_{\theta}(\hat{\theta}) = E_{\theta}[(\hat{\theta}(X) - \theta)^2]$ 。
注意到： $MSE_{\theta}(\hat{\theta}) = Var_{\theta}(\hat{\theta}) + [E_{\theta}(\hat{\theta}) - \theta]^2$,其第一部分是波动,即不同组样本所得出估计值之间的波动,第二部分是偏差,若为无偏估计则第二部分为0,应有 $MSE_{\theta}(\hat{\theta}) = Var_{\theta}(\hat{\theta})$,那么显然,若有不同的估计,当然是方差较小者为优。
 - 平均绝对误差（不易计算）： $E_{\theta}(|\hat{\theta}(X) - \theta|)$
 - 最小方差无偏估计：即所有无偏估计中方差最小的一个。（minimum variance unbiased estimate,MVUE）
- 克拉默-拉奥方差下界

如何找到上文所说的最小方差无偏估计？（也即最小方差）

克拉默-拉奥方差下界： $Var_{\theta}(\hat{g}(X)) \geq (g'(\theta))^2 [nI(\theta)]^{-1}$,其中 $I(\theta) = E(\frac{\partial \ln f(X;\theta)}{\partial \theta})^2$ 为费希尔信息函数,表示样本量为1的样本中关于参数 θ 信息量的大小, $nI(\theta)$ 表示样本量为n的样本中关于参数 θ 信息量的大小。

点估计量的大样本理论

大样本即样本量 $n \rightarrow \infty$ 时的估计量的性质,样本量固定的情况称为小样本性质。区别在于样本量是固定的还是动态的（趋于无穷的动态）。

- 相合性：样本量 $n \rightarrow \infty$ 时,有 $\hat{\theta} \xrightarrow{P} \theta$,则称 $\hat{\theta}$ 是 θ 的一个（弱）相合估计量。相合性是估计量的基本要求。
- 渐进正态性：若 $\hat{\theta}$ 是参数 θ 的一个点估计,设它的方差存在,记 $Var_{\theta}(\hat{\theta}) = \sigma_n^2(\theta)$,若当样本量 $n \rightarrow \infty$ 时,有 $\lim_{n \rightarrow \infty} (\frac{\hat{\theta} - \theta}{\sigma_n(\theta)} \leq x) = \Phi(x), \forall x \in R$,则称点估计量 $\hat{\theta}$ 有渐进正态性。

区间估计

基本概念

- 区间估计,可靠度与精度
所谓区间估计,即是待估计的参数 θ 估计在某区间 $[\hat{\theta}_1, \hat{\theta}_2]$ 中。可靠度即希望 θ 在此区间中的概率尽可能大,精度即要求区间长度尽可能小。但可靠度与精度显然是一对矛盾。
- 置信区间与置信系数
设 X 为总体中抽取的一个简单随机样本, $\theta \in \Theta$ 为未知参数,而 $\hat{\theta}_1 < \hat{\theta}_2$ 为两个估计量,现有 $\alpha \in (0, 1)$,若 $P_{\theta}(\hat{\theta}_1 \leq \theta \leq \hat{\theta}_2) = 1 - \alpha$,则称 $[\hat{\theta}_1, \hat{\theta}_2]$ 为置信区间,置信系数为 $1 - \alpha$ 。

枢轴变量法

直观上,未知参数应该在其优良点估计附近,故提出枢轴变量法(求解置信区间)的概念,即以其优良点估计为中心,向两侧扩展,寻找到符合置信系数的区间。可表示为 $[\hat{\theta} - d, \hat{\theta} + d]$,其中 d 被称为误差界限,求解置信区间也就是求解 d 与 $\hat{\theta}$ 。

步骤：假设待估计参数为 θ ,也就是构造出一些已知量和已知分布规律求解未知量即待估计参数的过程

1. 找到其的优良点估计 $T(X)$,一般为最大似然估计
2. 构造一个函数 $S(T, U, \theta)$ 称为枢轴变量,其分布已知,分布仅能是 T 与 θ 的函数。
3. 枢轴变量需满足要求 $a \leq S \leq b$ 可解得 $A \leq \theta \leq B$,其中A,B为T,a,b的函数,取分布的上 α 分位数和下 α 分位数,由定义,有 $P(w_{1-\alpha/2} \leq S \leq w_{\alpha/2}) = 1 - \alpha$,然后进行求解
4. $[A, B]$ 即为所求置信区间。

大样本方法

顾名思义,即样本量较大,需使用极限定理,中心极限定理建立枢轴变量。不过一般进行比较简单的如比例 p 的区间估计和样本均值的区间估计。

- p 的估计：二项分布在样本数量趋于无穷大时整体依分布收敛与正态分布,经过标准化变换可以转为标准正态分布 $\Phi(x)$ 。以 Y_n 记事件发生次数,成功概率为 p ,作 n 次独立实验,由中心极限定理,近似有： $\frac{Y_n - np}{\sqrt{np(1-p)}} \sim N(0, 1)$
 - 得分区间：即比例 p 的置信区间 $P \in \hat{p} \pm u_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$,此为瓦尔德置信区间,是原公式的简化,在 $n \rightarrow \infty$ 时可应用。
 - 瓦尔德区间宽度所需样本量：可以推导出 $n = \frac{4u_{\alpha/2}^2 \hat{p}(1-\hat{p})}{w^2}$ 。 w 为区间宽度。
 - 保守法求解样本量：即瓦尔德区间宽度与原区间宽度表达式均是 $\hat{p} = 0.5$ 时达到最大,故取 $\hat{p} = 0.5$ 计算样本量,即所有 $p \in (0, 1)$ 的置信区间宽度最多为 $\hat{p} = 0.5$ 时的 w ,即一个比较保守的样本量。
- 一般总体均值的估计： $(X_1, X_2, \dots, X_n) \in X$ 为一个样本,此时我们并不知道总体分布形式,但是由中心极限定理,标准化后依分布收敛于标准正态分布。此时样本方差是总体方差的相合估计,故可以代之。

自助法置信区间

抽样分布与自助分布的定义与比较

- 抽样分布：从总体中随机多次的抽取样本量为 n 的样本 X_0 ,**不同样本**计算得出的同一统计量的分布称为**抽样分布**。
- 自助分布：从总体中得到一个样本量为 n 的样本 X_1 ,从该样本中随机重复的抽取样本量 $X_2, X_3, X_4, X_5, \dots, X_m$,其中具体抽取方式为,当抽取某个样本 X_i 时,从原样本 X_1 中,抽取一个值并放回,如此抽取 n 次,正是如此抽取方式构成了不同的样本量为 n 的样本 $X_1, X_2, X_3, X_4, X_5, \dots, X_m$ 。根据**这些样本**计算出的同一统计量的值的分布称为**自助分布**。

通过上面的比较不难看出,自助法应用于样本量或总体量比较小的情况。抽取 B 次,其中常取 $B=1000$ 。

置信区间

较常用的枢轴变量有两种：

1. $\hat{\theta} - \theta$,其中 $\hat{\theta}$ 为已知参数 θ 的良好点估计。
2. $\frac{\hat{\theta} - \theta}{se(\hat{\theta})}$,其中 $se(\hat{\theta})$ 为样本标准差。

与其对应的置信区间也有两种：

1. $\hat{\theta} - \theta$ ：基本自助置信区间
 - 置信区间为 $[2\hat{\theta} - \hat{\theta}_{[(B+1)(1-\alpha/2)]}, 2\hat{\theta} + \hat{\theta}_{[(B+1)(\alpha/2)]}]$
2. $\frac{\hat{\theta} - \theta}{se(\hat{\theta})}$ ：自助t分布置信区间

- 置信区间为 $[\hat{\theta} - \hat{t}_{1-\alpha/2}^* \hat{se}_B(\hat{\theta}), \hat{\theta} - \hat{t}_{\alpha/2}^* \hat{se}_B(\hat{\theta})]$
- 计算步骤：样本值为 $x = (x_1, x_2, \dots, x_n)$,待计算参数为 θ
 - 得到B个自助样本 $X_1, X_2, \dots, X_B$;
 - 分别计算 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_B$;
 - 分别计算 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_B$ 的标准差 $\hat{se}_1(\hat{\theta}), \hat{se}_2(\hat{\theta}), \dots, \hat{se}_B(\hat{\theta})$: 此处需要将每个样本 $\hat{\theta}_b$ 分别进行R次自助法算得R个 $\hat{\theta}_{bi}$,其中 $b = 1, 2, \dots, B; i = 1, 2, \dots, R$ 。不然没法计算每个估计值的标准差;
 - 构造统计量 $t = \frac{\hat{\theta}_b^* - \theta}{se_R(\hat{\theta}_b^*)}$,此处要找出起上下 $\alpha/2$ 分位数;
 - 根据 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_B$ 计算出 $\hat{se}_B(\hat{\theta})$ 。在很多情况是不知晓总体标准差的,这一步是对总体标准差的估计;
 - 得出结果。

置信限

很多时候我们只关注参数 θ 取值范围的一侧：如95%的概率大于多少,或95%的概率小于多少。这并不是严格的小于等于或大于等于,而是多大的可能性大于或小于某个值。

$(X_1, X_2, \dots, X_n)$ 为总体中抽取的一个样本, $\overline{\theta} = \overline{\theta}(X_1, X_2, \dots, X_n), \underline{\theta} = \underline{\theta}(X_1, X_2, \dots, X_n)$ 为两个统计量。若：

- $P_{\theta}(\theta < \overline{\theta}) = 1 - \alpha$,则 $\overline{\theta}$ 是其置信上限;
- $P_{\theta}(\theta > \underline{\theta}) = 1 - \alpha$,则 $\underline{\theta}$ 是其置信下限;

假设检验

本章主要为参数假设检验。

假设检验的基本过程为,提出原假设和备择假设,通过已有条件完成对原假设的支持或推翻,这其中包括了一些判断条件。

基本概念

- 原假设与备择假设：原假设即原有假设,是原有条件或事实,备择假设是原假设的对立命题。
- 简单假设与复合假设：只有一个值的假设称为简单假设,否则为复合假设。
- 检验统计量、接受域与拒绝域、临界值：检验假设时用到的统计量称为假设统计量,拒绝域即原假设被拒绝的区域,接受域为原假设被接受的区域。临界值一般为接受域和拒绝域的分界线。
- 功效函数：不同的检验方法功效不同。 $\theta \in \Theta$ 为参数, H_0 是关于该参数的一个原假设,设 Φ 为一个检验,则称 $\beta_{\Phi} = P_{\theta}$ 为检验 Φ 的功效函数,其意义为,在检验 Φ 下 H_0 被否定的概率大小。
 - 当参数属于原假设时,我们希望功效函数尽量小;若属于备择假设,我们则希望其尽量大。拒绝 H_0 的能力称为功效。
 - 检验水平： $\alpha \in (0, 1)$,若 $\beta_{\Phi}(\theta) \leq \alpha$ 则称检验 Φ 的水平为 α 。由定义可知,大于功效函数值的都为其水平,我们尽量找最小的水平。检验水平代表了该检验可以错误拒绝（可以犯错误）原假设所允许的最大概率。
- 两类错误（设阳性代表正确,阴性代表错误）
 - 第一类错误,假阴性： H_0 为正确但检验结果为错误;
 - 第二类错误,假阳性： H_0 为错误但检验结果为正确;
- 显著性检验：这两类错误是不可能同时减少的,它们是一对矛盾体,通俗来讲拒绝能力强了,假阳性减少,那么被误判为错误的个体会变多,反之亦然。只考虑控制第一类错误的检验叫显著性检验。

假设检验的过程,即（一般情况）构造包含待假设参数的统计量,其分布已知,这是为了方便计算;根据检验水平,求出拒绝域与接受域;根据样本值计算实际统计量的值,看其落在哪个域中。

正态总体参数检验

单个正态总体均值检验

- 总体方差已知
 - 枢轴变量： $Z = \frac{\sqrt{n}(\overline{X}-\mu_0)}{\sigma} \sim N(0, 1)$
- 总体方差未知
 - 枢轴变量： $Z = \frac{\sqrt{n}(\overline{X}-\mu_0)}{s} \sim t_{n-1}$

其中 μ_0 一般为原假设, $\overline{X}$ 一般为已给值,愚以为,如此设置,是用于比较原假设与给出值的差异性。

两个正态总体均值差的检验

- 成组比较：不要求两个正态总体样本量相等,比较的是他们均值的差值,是整体的差异,比如两种药的药效比较

。现有 $X = (X_1, X_2, \dots, X_m), Y = (Y_1, Y_2, \dots, Y_n)$,其共同的方差为 σ^2 。构造统计量 $Z = \frac{(\bar{X}-\bar{Y})-(\mu_1-\mu_2)}{\sigma\sqrt{\frac{1}{m}+\frac{1}{n}}}$,其计算过程与单个正态总体无

异。当方差未知且不相同时,将 σ^2 替换为 $S_T = \sqrt{\frac{(m-1)S_1^2+(n-1)S_2^2}{m+n-2}}$, S_1^2, S_2^2 分别为X,Y的样本标准差。

- 成对比较： $\{(X_1, Y_1), (X_2, Y_2), \dots, (X_n, Y_n)\}$,数据量相等且成对。数据对之间独立,而数据对内部通常不独立。是一种具体到数据个体的差异。计算上仍是标准化造出枢轴变量,其他无异。

正态总体方差的检验

意在比较两组数据的波动程度,如投资的风险程度等等。

统计量的构造：由大数定律, S^2 与 σ^2 差不多,故进行 S^2 与 σ_0^2 的比较。故构造 $T = \frac{(n-1)S^2}{\sigma_0^2} \sim \chi_{n-1}^2$ 。

比例p的检验

比例p的检验即二项分布或两点分布中的概率p。

设 $(X_1, X_2, \dots, X_n)$ 是0-1分布总体的一个样本,与上文类似,依然是构造统计量进行比较（三类原假设）。显然, $\bar{X}$ 是一个直观的统计量,它可以代表p的相对大小。但注意到 $X = \sum_{i=1}^n X_i \sim B(n, p)$,那么X的分布是更易得到的。设X的分布函数为 $F_P(x)$,由于其为离散型变量,可能不存在 C_k 使得 $F_{p_0}(C_k) = 1 - \alpha$,故有 $F_{p_0}(C_0) \leq 1 - \alpha \leq F_{p_0}(C_0 + 1)$ 。那么有三种检验：

- $\phi_1: X > C_0$ 时拒绝原假设,否则不能拒绝;
- $\phi_2: X > C_0 + 1$ 时拒绝原假设,否则不能拒绝;
- $\phi_3:$

- $X \leq C_0$ 不拒绝原假设
- $X > C_0 + 1$ 时拒绝原假设
- $X = C_0 + 1$ 时,从[0,1]中取一随机数U,若 $U > \frac{1-\alpha-F_{p_0}(C_0)}{F_{p_0}(C_0+1)-F_{p_0}(C_0)}$ 拒绝原假设,否则不能拒绝。这一步有些离散状态连续化的味道。

似然比检验 LRT

这是一种多参数假设检验的方法,其在假设检验中的地位就宛如最大似然原理在点估计之中的地位。考虑假设检验问题：

概念引出

$H_0: \theta \in \Theta_0 \leftrightarrow H_1: \theta \in \Theta_1 = \Theta \setminus \Theta_0$ 。由极大似然估计的知识可知,我们优先选取概率密度更大的参数。参数是在 $\theta \in \Theta_0, \theta \in \Theta \setminus \Theta_0$ 中二选一,自然考虑两个量：

- $L_{\Theta_0}(x) = \sup_{\theta \in \Theta_0} f(x, \theta)$
- $L_{\Theta_1}(x) = \sup_{\theta \in \Theta_1} f(x, \theta)$

比较大小,自然考虑比值 $L_{\Theta_1}(x)/L_{\Theta_0}(x)$,将其优化一下,改为： $LR(x) = \frac{L_{\Theta}(x)}{L_{\Theta_0}(x)} = \frac{\max\{L_{\Theta_0}(x), L_{\Theta_1}(x)\}}{L_{\Theta_0}(x)} = \max\{\frac{L_{\Theta_1}(x)}{L_{\Theta_0}(x)}, 1\} = \frac{\sup_{\theta \in \Theta} f(x, \theta)}{\sup_{\theta \in \Theta_0} f(x, \theta)}$ 为检验的似然比。则由此定义的检验 ϕ :当 $LR(x) > c$ 时拒绝原假设,否则不拒绝,其中常数c可通过检验水平确定。其中c不一定为1,故可以出现原假设成立,并且 $L_{\Theta_0} < L_{\Theta_1}$ 的情况。

威尔克斯定理

设 Θ 的维数为 k, Θ_0 的维数为 s ,若 $k - s = t > 0$,则对于似然比检验有如下极限分布：在原假设成立的条件下,若样本量 $n \rightarrow \infty$ 时,有：

$P(2\ln(LR(X) \leq x)) \rightarrow F_{\chi_t^2}(x), \forall x \in \mathbb{R}$ 。记为 $2\ln LR(X) \xrightarrow{d} \chi_t^2$ 。

有此分布可以根据条件给出接受域与拒绝域。比如,若是根据前文的概念引出,设水平为 α ,则拒绝域为 $2\ln LR(X) > \chi_{m-1}^2(\alpha)$

p值

我们知道,一般是利用样本值计算出统计量然后判断是落在拒绝域中还是接受域中,这是一个检验的过程。假如有多组不同的样本都可以拒绝原假设,那么如何比较哪组样本拒绝原假设能力更强呢？从直观上来看,越极端的样本出现了,那么拒绝原假设的能力就越强。为此引入p值的概念：

p 值= P (得到当前样本下检验统计量的值或更极端值|原假设下)。

设检验水平为 α ,显然 p 值是不能超过检验的水平。 p 值是当前样本值条件下的显著性水平。为此得到一个检验： $p < \alpha, T \in H_1$,即可以拒绝原假设。

非参数假设检验

拟合优度检验

有时候样本值只有有限个值,我们不知道总体的分布是什么样的。此时要检验的是这个总体是什么分布,原假设一般为假定的某种分布,称为**理论分布**,直观上来看,拟合程度好,就接受原假设,反之拒绝。这是对总体分布形式的检验。这一类检验用到的统计量一般近似服从 χ^2 分布,由Pearson首先提出,被称为**皮尔逊 χ^2 检验**,也就是科研中常见的几种**卡方检验**之一。

PS:常见的卡方检验:

- 皮尔逊卡方检验
- 叶氏连续性校正
- 一元混成检验

理论分布已知且只有有限个值

假设理论分布为 $P(X = a_i) = p_i, i = 1, 2, \dots, k$, 样本为 $\{n_i \cdot a_i\}, \sum n_i = n$, n 为样本量。设 E 为每个类别(a_i)的期望值,而 O 为每个类别的观测值,有如下表格:

类别	a_1	a_2	...	a_k
E	np_1	np_2	...	np_k
O	n_1	n_2	...	n_k
$E - O$	$np_1 - n_1$	$np_2 - n_2$	...	$np_k - n_k$

最后一行维差值,显然其值越小,便越能接受原假设。现在的问题是如何构建统计量去衡量和说明这件事情,因此构建统计量: $Z = \sum \frac{(O-E)^2}{E} = \sum_{i=1}^k \frac{(np_i - n_i)^2}{np_i} = \sum_{i=1}^k \frac{n_i^2}{np_i} - n; n \rightarrow \infty, Z \sim \chi_{k-1}^2$.

拟合优度: 假如一组数据算得的统计量 $Z = Z_0, P(Z_0) = P(Z \geq Z_0) = 1 - F_{\chi_k^2}(Z_0)$ 被称为拟合优度 (根据此例所得的拟合优度), 显然拟合优度越大拟合效果就越好,拟合优度小于检验水平时拒绝原假设。拟合优度越高越好,但如果过高,要么运气太好,要有可能在造假。

理论分布类型已知但有有限个未知参数

理论分布为 $P(X = a_i) = p_i(\theta_1, \theta_2, \dots, \theta_r), i = 1, 2, \dots, k$, 其中 $\theta_1, \theta_2, \dots, \theta_r$ 为未知参数。也就是说,当我们构建统计量 Z 的时候,有一些参数无法得知,无法由此算出理论分布,那么根据之前学过的点估计理论,我们只能使用点估计方法。首先对 $\theta_1, \theta_2, \dots, \theta_r$ 进行点估计得到 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_r$,再算出 $\hat{p}_1, \hat{p}_2, \dots, \hat{p}_k$,由此得到各种类别的期望值的估计值,简单改换统计量计算公式为: $Z = \sum \frac{(O-E)^2}{E} = \sum_{i=1}^k \frac{(n\hat{p}_i - n_i)^2}{n\hat{p}_i} = \sum_{i=1}^k \frac{n_i^2}{n\hat{p}_i} - n$; 且 $n \rightarrow \infty$ 时, $Z \sim \chi_{k-r-1}^2$ 。

列联表检验

主要检验两个属性之间的相关性,其数据一般以二维表格形式呈现。

构造统计量: $Z = \sum_{i=1}^a \sum_{j=1}^b \frac{(n_{ij} - n_{i \cdot} n_{\cdot j} / n)^2}{n_{i \cdot} n_{\cdot j} / n}; Z \sim \chi_{(a-1)(b-1)}^2$ 。其中 $n_{i \cdot} n_{\cdot j} / n$ 为表格 (j, i) 位置上的期望值,即所希望的值,并非真实值。表格索引为列主序。

威尔克森秩和检验 Wilcoxon Rank-Sum Test

用于推断两个独立的连续型总体分布是否存在显著差异。它是独立样本 t 检验的非参数替代方案。

- 基本思想:** 将两组样本混合并从小到大排列,赋予每个数值一个“秩” (名次)。如果两组样本来自同一总体,那么它们的平均秩应当相近。
- 操作步骤:**
 - 混合样本并排序 (若有相同数值,取秩的平均值)。
 - 分别计算两组样本的秩和 W_1 和 W_2 。
 - 检验统计量:** 通常取较小样本量的秩和 W 。在样本量较大时 ($n > 10$) , W 近似服从正态分布。
- 适用场景:**
 - 数据不满足正态分布。
 - 数据为等级资料 (如: 满意度评分)。
 - 样本量较小且方差不齐。

符号检验 Sign Test

最简单的非参数检验方法,仅利用样本观测值相对于某个中心值 (通常是中位数) 的正负号,而不考虑其绝对大小。

- 基本思想:** 在原假设下,观测值大于中位数和小于中位数的概率各占 50% (类似于硬币正反面)。
- 应用类型:**
 - 单样本中位数检验:** 检验总体中位数是否等于某个常数 M_0 。
 - 配对样本比较:** 计算成对观测值的差值 $D_i = X_i - Y_i$,观察正号和负号的数量。

3. 检验统计量:

- 设 n_+ 为正号个数, n_- 为负号个数。在 H_0 下, $n_+ \sim B(n, 0.5)$ 。
- 通过二项分布计算 P 值。

4. 优缺点:

- 优点:** 对数据分布几乎没有要求,甚至不要求连续性。
- 缺点:** 由于完全丢弃了数值大小信息,其统计效能 (Power) 通常比威尔克森检验低。

其他非参数检验

1. 威尔克森符号秩检验 (Wilcoxon Signed-Rank Test)

- 区别:** 它是符号检验的升级版。它不仅考虑差值的符号,还考虑了差值绝对值的大小 (排序)。
- 用途:** 用于**配对样本** (如: 同一受试者用药前后的效果) 或单样本中位数检验。

2. 克鲁斯卡尔-沃利斯检验 (Kruskal-Wallis Test)

- 地位:** 单因素方差分析 (ANOVA) 的非参数版本。
- 用途:** 用于比较**三组或更多独立样本**的分布是否存在差异。
- 原理:** 将多组数据混合排序,计算各组的平均秩。

3. 列文检验 (Levene's Test)

- 用途:** 检验多组样本的**方差齐性**。
- 特点:** 虽然它常用于参数检验的前置条件检查,但它对非正态性比传统 F 检验更稳健。

4. 卡方独立性检验 (χ^2 Test of Independence)

- 用途:** 用于分类变量 (定类数据) 的相关性分析。
- 原理:** 基于“观察频数”与“理论频数”的偏离程度。

$$\chi^2 = \sum \frac{(O - E)^2}{E}$$

相关分析与回归分析

相关分析 Correlation Analysis

用于研究两个或多个随机变量之间关系的密切程度。

1. 皮尔逊相关系数 (Pearson Correlation Coefficient):

衡量两个连续变量之间的**线性**相关程度。

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}$$

- 取值范围:** $[-1, 1]$ 。
 - $r > 0$ 正相关, $r < 0$ 负相关。
 - $|r| \rightarrow 1$ 线性关系越强, $r = 0$ 表示无线性相关 (但不一定无关系)。
- 性质:** 单位无关性;对称性。

2. 斯皮尔曼等级相关 (Spearman's Rank Correlation):

非参数方法,利用秩次计算。适用于不满足正态分布或非线性 (但单调) 的数据。

3. 散点图 (Scatter Plot):

相关分析的首要步骤,通过直观观察判断是否存在离群点、非线性趋势或分群现象。

回归分析 Regression Analysis

通过建立数学模型来描述自变量 (X) 与因变量 (Y) 之间的定量关系。

1. 一元线性回归模型:

$$Y = \beta_0 + \beta_1 X + \epsilon, \quad \epsilon \sim N(0, \sigma^2)$$

- β_0 : 截距; β_1 : 斜率 (回归系数)。
- 参数估计:** 采用**最小二乘法 (OLS)**,使残差平方和 $Q = \sum (y_i - \hat{y}_i)^2$ 达到最小。

2. 回归方程的显著性检验:

- F 检验:** 检验整个方程是否显著 ($H_0: \beta_1 = 0$)。
- t 检验:** 检验特定系数是否显著。在一元回归中, t 检验与 F 检验等价。

3. 拟合优度 (R^2):

衡量模型解释数据变异的能力。

$$R^2 = \frac{SSR(\text{回归平方和})}{SST(\text{总平方和})} = 1 - \frac{SSE}{SST}$$

- R^2 越接近 1, 模型拟合效果越好。

多元回归中的自变量选择与模型诊断

在多元回归中,并非自变量越多越好 (过拟合风险),且需确保模型符合基本假设。

1. 自变量选择 (Variable Selection):

- 准则:
 - AIC / BIC**: 权衡拟合优度与参数个数,越小越好。
 - 调整后 R^2 : 惩罚了增加无用变量导致的人为拟合提升。
- 常用方法:
 - 向前选择 (Forward)**: 从空模型开始,逐个加入最显著变量。
 - 向后剔除 (Backward)**: 从全模型开始,逐个剔除最不显著变量。
 - 逐步回归 (Stepwise)**: 双向调整,加入新变量的同时重新检验已存在的变量。

2. 模型诊断 (Model Diagnosis):

- 残差分析 (Residual Analysis)**:
 - 正态性**: 残差应服从正态分布 (通过 QQ 图检查)。
 - 齐方差性**: 残差的波动不随预测值的变化而变化。
 - 独立性**: 残差间无自相关 (Durbin-Watson 检验)。
- 多重共线性 (Multicollinearity)**:
 - 指自变量间高度相关,导致系数估计不稳定。
 - 诊断指标: 方差膨胀因子 (VIF)**。通常 $VIF > 10$ 时认为存在严重的共线性。
- 异常值与强影响点**:
 - 库克距离 (Cook's Distance)**: 衡量单个样本点对回归系数的影响程度。

附录

本书无附录。